

OccSora: 作为自动驾驶世界模拟器的 4D 占据生成模型

王列宁^{1,2,*}, 郑文昭^{2,3,*}, 任一龙¹, 江涵¹, 崔志勇¹, 于海洋¹, 卢继文³

<https://wzzheng.net/OccSora>

¹ 中国北京航空航天大学智能交通系统国家重点实验室 ² 美国加州大学伯克利分校电子工程与计算机科学系 ³ 中国清华大学自动化系

leningwang@buaa.edu.cn; wenzhao.zheng@outlook.com

摘要

理解 3D 场景的演变对于有效的自动驾驶至关重要。传统方法通过单个实例的运动来建模场景发展，而世界模型则作为一种生成框架出现，用于描述一般的场景动态。然而，大多数现有方法采用自回归框架进行下一个标记的预测，这在建模长期时间演变时存在效率低下的问题。为了解决这一问题，我们提出了一种基于扩散的 4D 占据生成模型 OccSora，用于模拟自动驾驶中 3D 世界的发展。我们采用 4D 场景标记器来获取 4D 占据输入的紧凑离散时空表示，并实现长序列占据视频的高质量重建。然后，我们在时空表示上学习扩散 Transformer，并在轨迹提示的条件下生成 4D 占据。我们在广泛使用的 nuScenes 数据集上进行了大量实验，该数据集带有 Occ3D 占据注释。OccSora 能够生成具有真实 3D 布局和时间一致性的 16 秒视频，展示了其理解驾驶场景时空分布的能力。通过轨迹感知的 4D 生成，OccSora 有潜力作为自动驾驶决策的世界模拟器。代码可在以下网址获取：<https://github.com/wzzheng/OccSora>。

1 引言

作为人工智能技术的一个极具前景的应用，自动驾驶近年来受到了广泛的关注和研究 [16, 7, 46]。建立自动驾驶中感知 [27, 3, 4, 29]、预测 [14, 11, 24] 和规划 [32, 19, 20, 41] 之间的关系，对于全面理解该领域至关重要。

传统的自动驾驶模型 [16] 依赖自车实例的运动来建模场景的发展，无法形成与人类理解水平相当的对场景感知和车辆运动控制的深刻理解。世界模型 [12] 的出现为更深入理解自动驾驶场景与车辆运动之间的综合关系提供了新的可能。基于强大的图像预训练模型，基于图像的世界模型 [15, 42] 能够在 3D 边界框的条件下生成高质量的驾驶场景图像。OccWorld [53] 进一步在 3D 占据空间中学习世界模型，这能更好地用于自动驾驶的 3D 推理。然而，大多数现有方法采用自回归框架来建模 3D 场景的动态（例如图像令牌、边界框、占据情况），这阻碍了它们高效生成长期视频序列的能力。

* 同等贡献。† 在加州大学伯克利分校实习期间完成的工作。‡ 项目负责人。




图 1: 与现有方法的比较。它能够理解场景和轨迹之间的复杂关系, 并生成长期、物理一致的 4D 占据情况。

为解决这一问题, 我们受 OpenAI 的 2D 视频生成模型 Sora [1] 的启发, 提出了一种 4D 世界模型 OccSora, 如图 1 所示, 该模型通过扩散模型直接生成时空表征。为准确理解和表示 4D 场景, 我们设计了 4D 场景离散化方法以捕捉场景的动态特征, 并提出了一种基于扩散的世界模型, 以实现遵循物理规律的可控场景生成。具体而言, 在 4D 占据场景编码器中, 我们着重于提取和压缩真实的 4D 场景, 以建立对世界模型环境的理解。在基于扩散的世界模型中, 我们采用多维扩散技术来传播准确的时空 4D 信息, 并通过融入真实的自动驾驶汽车轨迹作为条件, 实现轨迹可控的场景生成, 从而深化对自动驾驶场景与车辆运动控制之间关系的理解。通过训练和测试, OccSora 能够生成符合物理逻辑的自动驾驶 4D 占据场景, 并基于不同轨迹实现可控的场景生成。所提出的自动驾驶 4D 世界模型为理解自动驾驶及物理世界中的动态场景变化开辟了新的可能。

2 相关工作

3D 占用预测。3D 占用的重点是将空间划分为体素, 并为每个体素分配特定的语义类型。在自动驾驶感知任务中, 继 3D 目标检测 [29, 28, 48] 和鸟瞰图 (BEV) 感知 [47, 52, 40, 51] 之后, 它被视为表示真实世界场景的关键手段。关于这一任务的早期研究主要集中于对激光雷达 (LiDAR) 的离散点进行语义分类 [55, 36, 25, 56]。事实上, 由于相机所包含的语义信息远超激光雷达, 且成本较低。因此, 利用图像进行深度估计或采用端到端方法进行 3D 场景感知研究是当前的主流方法 [18, 23, 44, 17]。考虑到多传感器系统的优势, 一些研究对用于 3D 占用预测的多模态融合展开了研究 [43, 49]。

除了利用典型的传感器设备进行 3D 占用预测外, 一些研究还关注其他涉及占用的任务。例如, OccWorld [53] 提出了一种时空生成转换器, 用于预测后续的场景令牌和车辆令牌, 从而预测未来的占用情况和车辆轨迹。另一方面, GenOcc [39] 利用生成模型来完成占用预测。DriveWorld [31] 引入了一个基于世界模型的框架, 用于从 2D 图像和视频中学习自动驾驶相关内容, 处理 3D 目标检测、在线地图创建和占用预测等任务。尽管在 3D 占用预测和连续 4D 预测方面取得了进展, 但这些研究的范围仍然有限。它们通常结合前几帧的场景信息使用自回归模型来执行后续的占用任务, 因此需要先验的场景或 3D 边界框输入。因此, 它们缺乏对场景和运动之间基本关系的真正理解, 也就不构成以动作作为条件的世界模型。

生成模型。近年来, 生成模型凭借其强大的能力受到了广泛关注。通过学习数据的概率分布, 生成模型能够训练出可以生成新样本的模型。从生成对抗网络 (GAN) [10] 的出现, 到最近变分自编码器 (VAE) [37] 等扩散模型的问世, 生成模型的任务已从最初的图像生成任务逐渐扩展到对视频的深入研究 [45]。基于 DIT 模型 [34] 的图像生成等任务深入探索并利用了其生成能力。Sora 视频生成模型 [1] 进一步展示了在连续场景中生成高质量视频的能力, 且帧间过渡自然逼真。

同样, 在自动驾驶领域, 可控图像生成可以提供各种驾驶场景, 为感知、规划、控制和决策任务服务。例如,




图 2: OccSora 的流程。4D 占用场景分词器实现真实信息的压缩与恢复。压缩后的信息和车辆轨迹同时作为基于扩散的世界模型的输入。训练完成后，基于扩散的世界模型利用随机噪声和任意轨迹生成可控的令牌，然后在 4D 占用场景分词器阶段将这些令牌解码为 4D 占用图。

MagicDriver [8] 通过学习自动驾驶车辆的视频并整合目标检测框和地图等标签，生成描绘各种天气场景的视频。DriveDreamer [42] 提出了一种完全源自真实驾驶场景的世界模型，能够深入理解结构化交通约束，从而实现精确且可控的视频生成。然而，对于自动驾驶场景而言，获取场景的三维占据信息比二维信息更为重要 [50, 30, 35]。一些研究 [22, 26] 提出了适用于生成室外真实场景的三维扩散模型，该模型利用扩散方法，完成了可扩展的无缝场景生成任务。尽管以往有研究生成二维静态图像并通过自回归将其扩展到时间维度，还有研究实现了三维占据场景的静态生成，但基于三维目标边界框生成的二维图像以及静态大规模场景都难以直接应用于自动驾驶任务 [41, 54]。相比之下，我们提出的 OccSora 建立了一个动态的四维占据世界模型，能够随着车辆轨迹适应场景变化，无需任何预先的目标检测框或场景信息，是首个面向自动驾驶的生成式四维占据世界模型。

3 提出的方法

3.1 自动驾驶世界模型

4D 占据可以全面捕捉 3D 场景的结构、语义和时间信息，并有效促进弱监督或自监督学习，可应用于视觉、激光雷达或多模态任务。基于这些原理，我们将世界模型 x 表示为 4D 占据 R 。图 2 展示了 OccSora 的整体框架。我们构建了一个 4D 占据

场景分词器用于压缩真实的 4D 占据 $R_o \in \mathbb{R}^{B \times D \times H \times W \times T}$ 并在时间维度 T 上存在空间 $D \times H \times W$ 维度。捕捉 4D 自主系统中的关系和演化模式。

驾驶场景。这会产生压缩的高级令牌 $R_{mi} \in \mathbb{R}^{B \times c \times h \times w \times t}$ 和重建的 4D 占据数据 $R_o \in \mathbb{R}^{B \times D \times H \times W \times T}$ 。我们设计了一个基于扩散的世界模型，该模型使用轨迹信息 $R_{tr} \in \mathbb{R}^{B \times T \times 2}$ 作为控制单元，在压缩令牌 R_{mi} 的监督下进行训练，以生成高维场景表示令牌 $T_o \in \mathbb{R}^{B \times c \times h \times w \times t}$ 。它们是

然后由 4D 占用场景分词器解码为一致且可动态控制的 R_o 。

3.2 4D 占据场景分词器

4D 占据预测的目标是确定特定位置在不同时间的语义类型。

我们将真实的 4D 占据场景 R_o 离散化并编码到中间潜在空间 z_{mi} 中。

为了获得 4D 占用场景的真实表示，如图 3 所示。公式如下： $R_{mi} = \text{tokenize}(R_o)$ 。这里， tokenize 表示编码的码本， tokenize 表示设计的 3D 编码器网络和类别嵌入。这种 3D 占用表示将




图 3: 4D 占用场景分词器的结构。所提出的方法对 4D 场景进行编码和压缩以提取高维特征，然后对这些特征进行解码，以获取场景的时空物理特性。

左轴周围的三维空间转换为体素 $T = N \in \mathbb{N} \times H \times W \times D$ 其中每个体素位置是

为其分配一个类型标签 N ，用于指示它是否被占据以及占据它的对象的语义。与传统方法不同，我们在同一场景中整合并压缩时间信息，将张量重塑为 R_{in} 。与之前的自回归方法相比，这种方法能够统一学习空间和时间演化模式以及真实场景的物理关系。经过带有类别嵌入的 ζ_{token} 三维编码器网络和 ζ_{token} 编码码本后，该张量被转换为 R_{mi} ，代表潜在空间。这种重塑确保了对 4D 占用的时间动态的全面表示。

类别嵌入与分词器。为了准确捕捉原始参数的空间信息，我们首先对输入的 R_{in} 执行嵌入操作。我们为 R_{in} 中的每个类别分配一个可学习的类别嵌入 $b \in \mathbb{R}^C$ ，以标记连续 3D 占据场景的类别。位置信息被嵌入为代表类别的标记。然后，这些嵌入沿着特征维度进行拼接。为了便于后续的 3D 编码，我们

在特定维度上进行压缩后，我们进一步将 R_{in} 重塑为 $R_{in} \in \mathbb{R}^{B \times (D \times D \times D) \times T \times H \times W}$

3D 视频编码器。为了有效地学习离散潜在标记，我们进一步对 4D 占位 D 的嵌入位置信息进行下采样，以提取高维特征。设计的编码器架构包括一系列 3D 下采样卷积层，这些层在时间维度 (T) 和空间维度 ($H \times W$) 上执行 3D 下采样，将融合维度增加到 $n \times D$ 。我们最初将输入 D 下采样三次，以获得

$D' \in \mathbb{R}^{B \times (8 \times D \times D \times D) \times \frac{T}{8} \times \frac{H}{8} \times \frac{W}{8}}$ 并在前馈层和注意力层之后引入了 dropout 层

用于正则化的块层。考虑到连续帧之间的关系，我们在降采样后引入了跨通道注意力，沿着 $8 \times D \times D$ 维度对 D' 进行分割，然后在分割后的部分之间执行跨通道注意力。此操作增强了模型捕捉不同轴上特征之间关系的能力，随后将它们重塑回原始形状，以获得输出张量 R_{mi} 。

码本和训练目标。为了获得更简洁的表示，我们同时学习一个包含 N 个代码的码本 $\zeta_{token} \in \mathbb{R}^{N \times D}$ 。码本中的每个代码 $b \in \mathbb{R}^C$ 都编码了场景的一个高级概念，例如相应位置是否有汽车。 ζ_{token} 表示编码后的码本。我们通过将 R_{mi} 中的每个空间特征 $D^{(ij)}$ 映射到最近的代码 $N(R^{(ij)}, \zeta_{token})$ 来对其进行量化

$$R_{mi}^{(ij)} = N(R^{(ij)}, \zeta_{token}) = \min_{b \in \zeta_{token}} \|R_{mi}^{(ij)} - b\|_2,$$

其中 $\|\cdot\|_2$ 表示 L2 范数。随后，我们对量化后的特征 $D^{(ij)}$ 进行整合，以获得最终的场景表示 R_{mi} 。

3D 视频解码器。为了从学习到的场景表示 R_{mi} 中重建 D ，我们设计了一个由 3D 反卷积层组成的解码器。与编码器不同，解码器架构包含跨通道注意力、残差块和一系列 3D 卷积，能够在时间和空间维度上进行上采样。这种渐进式上采样过程将 R_{mi} 转换为其原始占用分辨率 D 。然后，解码器沿着通道维度分割结果。




图 4: 基于扩散的世界模型结构。该模型利用通过训练 4D 占用场景分词器获得的最优码本，将 4D 占用转换为一系列标记。这些标记与自车轨迹和随机噪声相结合，作为去噪训练的输入，以获取生成的标记。

为了重建时间维度，生成每个体素的占用值。在训练过程中，我们完成了编码器、解码器参数以及编码码本的训练。所设计的网络使我们能够同时对输入的 4D 占用信息进行编码，并将其压缩为多个令牌，从而学习时空融合下世界模型的物理相关性。此外，我们在解码过程中对信息进行恢复。

3.3 基于扩散的世界模型

受扩散方法 [33] 的启发，我们使用包含时空信息特征的场景令牌 R_{mi} 作为生成模型的输入。此外，我们在车辆轨迹 R_{tr} 的控制下进行去噪训练和轨迹可控生成任务，如图 4 所示。

令牌嵌入。为了高效且准确地利用 Transformer [38]，我们将输入数据令牌 R_{mi} 展平为 R_{mi} 。同时，考虑到位置信息对时空压缩的重要性，我们对输入进行位置嵌入。我们设计了以下函数，该函数利用正弦和余弦函数对位置索引进行编码：

$$R_{mi}^{(emb)} = emb(d) + R_{mi} \quad R_{mi} \in \mathbb{R}^{B \times c \times (hwt)}$$

它基于两个主要参数运行： C ，表示每个位置的嵌入输出维度； $i = hwt$ ，表示枚举待编码位置的标记数量。生成的输出遵循维度为 $C \times i$ 的矩阵结构，emb 使用正弦和余弦函数构建位置嵌入表示。这些嵌入封装了标记的位置属性，增强了模型对输入中位置的理解。我们添加

将位置编码 $R_{mi}^{(emb)}$ 应用于输入 R_{mi} ，得到 $R_{mi}^{(emb)}$ ，它代表之后的标记。
位置编码。

轨迹条件嵌入。场景与轨迹之间的转换关系是自动驾驶的一个关键方面。生成与控制轨迹相符的多样化 4D 占用场景至关重要。因此，我们使用自车轨迹 T_{tr} 作为输入。

以生成可控的 4D 占用。首先，使用自车轨迹 $T_{tr} \in \mathbb{R}^{B \times t \times 2}$ 作为

控制输入之一，其中 t 表示连续时间维度，第三个维度表示车辆在绝对坐标系 x 轴和 y 轴上的位置。为了实现

轨迹嵌入和编码方面，我们将车辆轨迹重塑为 $T_{tr} \in \mathbb{R}^{B \times (t \times 2)}$ 并进行学习

并按如下方式对其进行编码：

$$\alpha = \mu(t) + \delta(T_{tr}) \quad \delta(T_{tr}) \in \mathbb{R}^{B \times c \times (hwt)} \quad \mu \in \mathbb{R}^{B \times c \times (hwt)}$$

其中， $\mu \in \mathbb{R}^{B \times c \times (hwt)}$ 代表时间步嵌入， δ 表示提取轨迹信息的多层感知器 (MLP) 网络。然后将 α 嵌入到扩散 transformer 的输入序列中，并与标记信息 $R_{mi}^{(emb)}$ 一起进行处理。

扩散 Transformer。我们开发了一个基于扩散的世界模型，用于在潜在空间 R_{mi} 中学习和生成，同时整合轨迹标签 T_{tr} 和去噪时间步“作为 con

控制条件。在模型扩散学习过程中，我们构建了一个正向噪声过程，该过程将噪声逐渐引入潜在空间 $p_{t+1} = \mathcal{N}(p_t | p_{t-1}) = \mathcal{N}(p_t \cdot \sqrt{\alpha p_{t-1}} + \sqrt{1 - \alpha} \epsilon_t)$ ，其中常数 g 表示轨迹和时间步长的嵌入。利用重参数化技巧，我们可以进行采样： $p_t = \sqrt{\alpha p_{t-1}} + \sqrt{1 - \alpha} q$ ，其中 $q \sim \mathcal{N}(0, I)$ 。4D 占用扩散模型经过训练，用于学习反向传播过程。为了逆转正向过程的损坏：

$$p_{t-1} | p_t = \mathcal{N}(p_{t-1} | p_t, \sigma^2(p_t))$$

其中神经网络预测 p 的统计特性。反向过程模型通过 p 的变分下界进行训练，这简化为： $\mathcal{L}(p) = -\mathbb{E}[\log p(p)]$

$\sum_{t=1}^T D_{KL}(q^*(p_{t-1}^0 | p_t^0, R_{p_{t-1}}^0) || p_{\theta}(p_{t-1}^0 | p_t^0))$ ，其中在训练过程中排除了不相关的附加项。

在训练过程中，由于 q 和 p 都是高斯分布，Kullback-Leibler (KL) 散度可以通过这两个分布的均值和协方差来计算。通过将其重新参数化为噪声预测网络，该模型可以利用预测噪声 $\hat{p}_t$ 与采样的高斯噪声 $p_t = \sqrt{\alpha p_{t-1}} + \sqrt{1 - \alpha} q$ 之间的简单均方误差进行训练。然而，要用学习到的反向过程协方差来训练扩散模型，就需要优化完整的 KL 散度项。我们遵循扩散模型的方法 [6]：首先用 $\mathcal{L}(p)$ 进行训练，然后用完整的 $\mathcal{L}$ 进行训练。一旦 p 训练完成，就可以通过初始化 $p_t \sim \mathcal{N}(0, I)$ 并进行采样来获得新的标记。

使用重参数化技巧对 $p_{t-1} = \mathcal{N}(p_{t-1} | p_t, \sigma^2(p_t))$ 进行采样。

总体而言，在初始阶段处理的令牌 R_{t-1} （标识为 R_{t-1} ）会被传递到一系列 Transformer 块中进行进一步优化。这些块能有效捕捉轨迹信息与令牌之间的关系。在处理含噪图像输入时，扩散 Transformer 采用特定的注意力机制和损失函数，以减少噪声对模型性能的影响，确保其在嘈杂环境中稳定运行。为了将轨迹标签 τ_t 和去噪时间步作为额外的控制条件，我们将它们与令牌嵌入一起作为补充输入送入 Transformer 块。这使模型能够根据这些条件动态调整其处理过程，从而更好地适应各种轨迹控制需求。最终，经过训练的基于扩散的世界模型成功地将噪声和轨迹标签进行转换。

τ_t 转换为 $\tau_t \in \mathbb{R}^{B \times c \times h \times w \times t}$ ，最终通过 3D 解码器解码为 R_{t-1} 。

4 实验

作为自动驾驶领域的 4D 占用世界模型，OccSora 无需任何 3D 边界框、地图或历史信息输入，就能更深入地理解自动驾驶场景与车辆轨迹之间的关系。它能够构建一个符合物理定律的长时序世界模型。我们已进行了一系列定量实验和可视化操作来对此加以说明。

4.1 实现细节

我们在广泛使用的 nuScenes-Occupancy 数据集 [2] 上进行了实验，该数据集目前是最主流和标准的数据集之一，支持许多知名的研究 [16,43]。对于 OccSora 模型，我们对 32 个连续帧进行了三轮压缩，并将其通道维度增加到 128。随后，我们在不同的组件和轨迹场景下进行了进一步的对比和消融实验。我们使用 AdamW 优化器进行训练，初始学习率设置为 1×10^{-5} ，权重衰减为 0.01。使用 8 块 NVIDIA GeForce A100 GPU，我们每块 GPU 设置的批处理大小为 2。对于 4D 占据场景分词器的训练，每块 GPU 需要约 42GB 内存来训练 150 个 epoch，耗时 50.6 小时。对于基于扩散的世界模型，每块 GPU 需要约 47GB 内存来训练 1,200,000 步，耗时 108 小时。

4.2 四维占据重建

4D 占据的压缩与重建对于学习图像生成所需的潜在时空相关性和特征至关重要。与传统的视频和图像处理模型不同，OccSora 的运行维度比单帧占据高一个维度。

表 1: 4D 占用重建的定量分析。尽管压缩率比 OccWorld 高 32 倍, OccSora 仍保持了 OccWorld 一半以上的重建精度。

Method	Ratio	IoU	mIoU	Others	barrier	bicycle	bus	car	const. veh.	motorcycle	pedestrian	traffic cone	trailer	truck	drive. suf.	other flat	sidewalk	terrain	man made	vegetation
OccWorld [53]	16	62.2	65.7	45.0	72.2	69.6	68.2	69.4	44.4	70.7	74.8	67.6	54.1	65.4	82.7	78.4	69.7	66.4	52.8	43.7
OccSora	512	37.0	27.4	11.7	22.6	0.0	34.6	29.0	16.6	8.7	11.5	3.5	20.1	29.0	61.3	38.7	36.5	31.1	12.0	18.4




图 5: 4D 占用场景生成器的重建可视化。

表 2: OccSora 与其生成能力方面其他模型的对比。据我们所知, 我们是首个 4D 占用生成模型。因此, 我们仅提供与不同数据集和数据格式上其他生成模型的对比。

Method	Type	Dimension	Dataset	FID
DiT [34]	Image	2D	ImageNet [5]	12.03
MagicDriver [8]	Video	3D	nuScenes [2]	14.46
DriveDreamer [42]	Video	3D	nuScenes [2]	14.9
DriveGAN [21]	Video	3D	nuScenes [2]	27.8
SemCity [22]	Occupancy	3D	KITTI [9]	40.63
OccSora	Occupancy Video	4D	nuScenes [2]	8.348




图 6: 随着模型进行迭代训练, 精确场景逐步生成的可视化展示。

并且比图像高出两个维度。因此, 实现高效压缩和准确重建至关重要。图 5 展示了占位率的真实值和重建结果。我们还对 4D 占位率重建进行了定量分析, 如表 1 所示。该表表明, 即使 OccSora 的压缩比是 OccWorld 的 32 倍, 它仍然保持了原始 OccWorld 模型近 50% 的 mIoU。这种统一的时间压缩有效地捕捉了各种元素的动态变化, 与渐进式自回归方法相比, 提高了长序列建模能力。

4.3 四维占据生成

在用于 4D 占据生成任务的基于扩散的世界模型中, 我们使用了由 OccSora 模型生成的令牌 (该模型经过 32 帧训练) 作为生成实验的输入。在图 6 中, 我们展示了从 10,000 步到 1,200,000 步不同训练迭代次数的视觉结果。这些视觉结果表明, 随着训练迭代次数的增加, OccSora 模型的准确性不断提高, 能够生成连贯的场景。

我们将所提出的 OccSora 模型与其他生成模型进行了比较和定量评估。作为首个用于自动驾驶的 4D 占用世界模型, 我们仅将其与传统的图像生成、2D 视频生成以及静态 3D 占用场景生成方法进行了对比。如表 2 所示, 我们的模型在弗雷歇 inception 距离 (FID) [13] 方面取得了相近的性能, 这证明了所提方法的有效性。




图 7: 不同输入轨迹下的 4D 占用生成。从上到下分别是直行、右转和静止，每个场景生成都与轨迹相对应，确保逻辑连贯和连续性。




图 8: 在轨迹控制下生成多样化的连续场景。生成的场景在保持原始轨迹控制稳定性的同时展现出多样性。

表 3: 不同组件的消融评估结果。我们通过控制变量，定量评估了不同压缩率、组件和通道维度对重建和生成结果的影响。

Input Size R_{in}	Token Size R_{mi}	Channel	Class	T embed.	Trajectory	IoU	mIoU	FID
32x200x200	128x4x25x25	8	✓	✓	✓	37.03	27.42	8.34
32x200x200	128x4x25x25	8	✓	✗	✓	37.03	27.42	87.26
32x200x200	128x4x25x25	8	✓	✓	✗	37.03	27.42	17.48
32x200x200	128x4x25x25	4	✓	✓	✓	29.67	23.21	34.24
32x200x200	128x8x50x50	8	✓	✓	✓	32.91	24.4	72.32
12x200x200	64x3x50x50	8	✓	✓	✓	26.73	14.12	187.78
12x200x200	64x3x25x25	8	✓	✓	✓	22.42	9.27	270.23
12x200x200	32x3x25x25	8	✓	✓	✓	13.60	3.85	465.18

轨迹视频生成。OccSora 能够基于不同的输入轨迹生成各种动态场景，从而学习自动驾驶中自车轨迹与场景演变之间的关系。如图 7 所示，我们将不同的车辆轨迹运动模式输入模型，展示了直行、右转和静止状态下的 4D 占用情况。我们在不同的轨迹生成尺度上进行了实验，结果显示静止场景的 FID 分数最低，曲线场景的 FID 分数较高，这表明对连续曲线运动场景进行建模的复杂性以及对静止场景进行建模的简单性。

场景视频生成。在合理的轨迹控制下，场景的多样性至关重要。我们在三条轨迹下测试了不同场景的 4D 占用场景重建，以验证在可控轨迹下生成场景的泛化性能。图 8 中，左右两部分分别展示了在相同轨迹下生成不同场景的能力。在重建的场景中，周围的树木和道路环境呈现出随机变化，但仍保持了原始轨迹的逻辑，这体现了在生成与原始轨迹对应的场景时保持稳健性的能力，以及其不同场景中的泛化能力。

表 4: 不同规模在去噪步骤和去噪率方面的定量分析。去噪步骤对模型的影响相对较小, 而去噪率和模型规模则显著影响生成结果的质量。

Step	Input Size R_{in}	Token Size R_{mi}	FID					
			10%	30%	50%	70%	90%	100%
10	32x200x200	128x4x25x25	49863	34927	17630	339	42	9.1
100	32x200x200	128x4x25x25	53297	29521	19471	1084	72	10.08
1000	32x200x200	128x4x25x25	32171	10284	5924	591	17	8.94
10	12x200x200	64x3x50x50	71293	54625	5644	7416	742	431
100	12x200x200	64x3x50x50	81274	53431	45346	3161	456	446
1000	12x200x200	64x3x50x50	43631	33415	17431	4366	379	353

图 9: 不同轨迹或去噪步骤下去噪率的影响。去噪步骤和轨迹的影响较小, 而去噪率的影响显著。

4.4 消融与分析

对分词器和嵌入的分析。我们对所提出的组件进行了消融实验, 包括不同的压缩比例、类别分词器离散化数量、时间步嵌入和车辆轨迹嵌入, 如表 3 所示。当类别分词器的离散化数量从 8 减少到 4 时, 重建精度下降了约 18%。移除时间步嵌入后, FID 分数也有所下降。没有位置嵌入时, 生成的场景缺乏运动控制, 并且受数据分布的影响呈现出几乎线性的运动模式。此外, 在较低的压缩比下, 尽管重建性能优于较高的压缩比, 但由于缺乏高维特征相关性, 无法生成有效的场景。

生成步骤分析。去噪步骤的总数和去噪率在在一定程度上会影响生成质量。如图 9 所示, 随着去噪率的提高, 生成的场景会逐渐变得清晰。根据表 4 中的定量结果, 增加去噪步骤的总数能在一定程度上提高生成精度。然而, 与去噪步骤的总数相比, 令牌大小和通道数量对生成质量的影响要显著得多。

5 结论与局限性

在本文中, 我们提出了一个用于生成 4D 占据情况的框架, 以模拟自动驾驶中的 3D 世界发展。通过 4D 场景分词器, 我们获得了输入的紧凑表示, 并实现了长序列占据情况视频的高质量重建。随后, 我们在时空表示上训练了一个扩散 Transformer, 并基于轨迹提示生成 4D 占据情况。通过在 nuScenes 数据集上的实验, 我们展示了精确的场景演变。未来, 我们将研究更精细的 4D 占据情况世界模型, 并探索闭环设置下端到端自动驾驶的可能性。

局限性。4D 占用世界模型的优势在于建立对场景和运动之间关系的理解。然而, 由于体系数据粒度的限制, 我们无法构建更精细的 4D 场景。生成结果还显示移动物体的细节不一致。这可能是由于训练数据量较小所致。

参考文献

- [1] 蒂姆·布鲁克斯、比尔·皮布尔斯、康纳·霍尔姆斯、威尔·德普、于飞·郭、李静、大卫·施努尔、乔·泰勒、特洛伊·卢曼、埃里克·卢曼、克拉伦斯·吴、瑞奇·王和阿迪蒂亚·拉梅什。作为世界模拟器的视频生成模型。2024 年。
- [2] 霍尔格·西泽、瓦伦·班基蒂、亚历克斯·H·朗、苏拉布·沃拉、威尼斯·艾琳·利昂、徐强、阿努什·克里希南、潘宇、吉安卡洛·巴尔丹和奥斯卡·贝伊博姆。nuscenes: 一个用于自动驾驶的多模态数据集。见《计算机视觉与模式识别会议论文集》, 第 11621-11631 页, 2020 年。
- [3] 程畅、张嘉伟、张鲲鹏、钟文钦、彭新宇、李申和李丽。BEVV2X: 基于 V2X 的数据共享实现协作式鸟瞰图融合与网格占用预测。《IEEE 智能车辆汇刊》, 2023 年。
- [4] 陈宣尧、张天元、王悦、王逸伦和赵航。Futr3d: 用于三维检测的统一传感器融合框架。发表于《CVPR》, 第 172-181 页, 2023 年。
- [5] 贾登、魏东、理查德·索切尔、李佳佳、李凯和李飞飞。ImageNet: 一个大规模的分层图像数据库。见《CVPR》, 第 248-255 页。电气和电子工程师协会, 2009 年。
- [6] 普拉富拉·达里瓦尔和亚历克斯·尼科尔。扩散模型在图像合成上击败生成对抗网络, 2021 年。
- [7] 傅道成、李鑫、文立成、窦敏、蔡品龙、石博天和乔宇。像人类一样驾驶: 用大型语言模型重新思考自动驾驶。收录于《WACV》, 第 910-919 页, 2024 年。
- [8] 高瑞远、陈凯、谢恩泽、洪兰清、李振国、杨迪严和徐强。Magicdrive: 具有多样化 3D 几何控制的街景生成。arXiv 预印本 arXiv:2310.02601, 2023。
- [9] 安德烈亚斯·盖格尔、菲利普·伦茨和拉克尔·乌尔塔松。我们准备好迎接自动驾驶了吗? KITTI 视觉基准套件。见《CVPR》, 第 3354-3361 页, IEEE, 2012 年。
- [10] 伊恩·古德费洛、让·普格特-阿巴迪、迈赫迪·米尔扎、徐冰、大卫·沃德-法利、谢尔吉尔·奥扎尔、亚伦·库维尔和约书亚·本吉奥。生成对抗网络。《ACM 通讯》, 63 (11): 139-144, 2020。
- [11] 顾俊儒、胡晨旭、张天元、陈宣尧、王逸伦、王悦和赵航。Vip3d: 通过 3D 智能体查询进行端到端视觉轨迹预测。arXiv 预印本 arXiv:2208.01582, 2022。
- [12] 大卫·哈 (David Ha) 和于尔根·施密德胡贝尔 (Jürgen Schmidhuber)。世界模型。2018 年。
- [13] 马丁·霍伊塞耳、休伯特·拉姆绍尔、托马斯·昂特蒂纳、伯恩哈德·内斯勒和塞普·霍赫赖特。通过双时标更新规则训练的生成对抗网络收敛于局部纳什均衡。2018 年。
- [14] 安东尼·胡、扎克·穆雷兹、尼基尔·莫汉、索菲亚·杜达丝、杰弗里·霍克、维贾伊·巴德里纳拉亚南、罗伯托·西波拉和亚历克斯·肯德尔。Fiery: 基于环视单目相机的鸟瞰图未来实例预测。发表于《国际计算机视觉大会》, 2021 年。
- [15] 安东尼·胡、劳埃德·拉塞尔、哈德森·杨、扎克·穆雷兹、乔治·费多西耶夫、亚历克斯·肯德尔、杰米·肖顿和吉安卢卡·科拉多。Gaia-1: 自动驾驶的生成式世界模型。arXiv 预印本 arXiv:2309.17080, 2023 年。
- [16] 胡一涵、杨家志、李晨、李可宇、司马崇浩、朱西周、柴思琪、杜森耀、林天伟、王文海等。面向规划的自动驾驶。发表于《CVPR》, 第 17853-17862 页, 2023 年。
- [17] 黄元辉、郑文昭、张博瑞、周洁、吕继文。Selfocc: 基于自监督视觉的三维占用预测。arXiv 预印本 arXiv:2311.12754, 2023。
- [18] 黄元辉、郑文昭、张运鹏、周洁、陆继文。基于视觉的三维语义占用预测的三视角视图。发表于《CVPR》, 第 9223-9232 页, 2023 年。
- [19] 黄志宇、刘浩辰、吴静达和吕晨。《用于自动驾驶的具有可学习成本函数的可微分集成运动预测与规划》。《IEEE 神经网络与学习系统汇刊》, 2023 年。
- [20] 贾小松、吴鹏浩、李晨、谢江伟、何聪辉、闫俊驰、李宏阳。驾驶前三思: 面向端到端自动驾驶的可扩展解码器。收录于《CVPR》, 第 21983-21994 页, 2023 年。
- [21] 金胜旭 (Seung Wook Kim)、乔纳·菲利昂 (Jonah Philion)、安东尼奥·托拉尔巴 (Antonio Torralba) 和桑娅·菲德勒 (Sanja Fidler)。Drivegan: 迈向可控的高质量神经模拟。发表于《CVPR》, 第 5820-5829 页, 2021 年 6 月。
- [22] 李柱民、李瑟彬、赵昌浩、林宇彬、孙周亨和尹成义。Semcity: 基于三平面扩散的语义场景生成。arXiv 预印本 arXiv:2403.07773, 2024。
- [23] 李明、余志鼎、克里斯托弗·蔡、肖超伟、何塞·M·阿尔瓦雷斯、桑贾·菲德勒、陈峰, 以及阿尼玛·阿南德库马尔。Voxformer: 用于基于相机的 3D 语义场景补全的稀疏体系 Transformer。发表于《CVPR》, 第 9087-9098 页, 2023 年。

- [24] 梁明、杨斌、曾文远、陈云、胡锐、塞尔吉奥·卡萨斯和拉克尔·乌塔松。Pnpnet: 具有闭环跟踪的端到端感知与预测。发表于《计算机视觉与模式识别会议》, 2020 年。
- [25] 刘欣浩、宫文俊、方琪、谢浩宇、李明、赵航和陈峰。基于激光雷达的 4D 占用率补全与预测。arXiv 预印本 arXiv:2310.11239, 2023。
- [26] 刘宇航、李新科、李雪婷、齐璐、李重寿和杨明轩。用于精细 3D 大场景生成的金字塔扩散。arXiv 预印本 arXiv:2311.12085, 2023。
- [27] 刘志坚、唐昊天、亚历山大·阿米尼、杨新宇、毛慧子、丹妮拉·L·鲁斯和宋涵。Bevfusion: 基于统一鸟瞰图表示的多任务多传感器融合。见《国际机器人与自动化会议论文集》, 第 2774-2781 页。IEEE, 2023 年。
- [28] 马新竹、欧阳万里、安德里亚·西蒙内利和艾丽莎·里奇。《面向自动驾驶的图像三维目标检测综述》。《IEEE 模式分析与机器智能汇刊》, 2023 年。
- [29] 毛家庚、时少帅、王小刚、李洪生。自动驾驶中的三维目标检测: 综述。《国际计算机视觉杂志》, 131 (8): 1909-1963, 2023。
- [30] 拉尔斯·梅舍德、迈克尔·奥克斯勒、迈克尔·尼迈耶、塞巴斯蒂安·诺沃津和安德烈亚斯·盖格尔。占用网络: 在函数空间中学习三维重建。发表于《CVPR》, 第 4460-4470 页, 2019 年。
- [31] 陈敏、赵大卫、肖亮、赵健、徐新丽、朱正、金磊、李建树、郭玉兰、邢俊亮等。Driveworld: 基于世界模型的自动驾驶 4D 预训练场景理解。arXiv 预印本 arXiv:2405.04390, 2024。
- [32] 萨贾德·莫扎法里、奥马尔·Y·贾拉、迈赫达德·迪亚纳蒂、保罗·詹宁斯和亚历山德罗斯·穆扎基蒂斯。面向自动驾驶应用的基于深度学习的车辆行为预测: 综述。《IEEE 智能交通系统汇刊》, 23 (1): 33-47, 2020。
- [33] 威廉·皮布尔斯和赛宁·谢。基于 Transformer 的可扩展扩散模型。arXiv 预印本 arXiv:2212.09748, 2022。
- [34] 威廉·皮布尔斯和赛宁·谢。基于 Transformer 的可扩展扩散模型。发表于《国际计算机视觉大会》, 第 4195-4205 页, 2023 年。
- [35] 司马崇浩、童文文、王泰、陈莉、吴思蕾、邓汉明、谷毅、陆乐伟、罗平、林达华和李宏阳。场景即占用。2023 年。
- [36] 古尔普雷特·辛格、苏米亚吉特·古普塔、马修·利斯和克林特·道森。Range-net: 一种用于大数据应用的高精度流式奇异值分解。arXiv 预印本 arXiv:2010.14226, 2020。
- [37] 亚伦·范登·奥德、奥里奥尔·文尼亚斯等人。神经离散表示学习。《神经信息处理系统进展》, 第 30 卷, 2017 年。
- [38] 阿希什·瓦斯瓦尼、诺阿姆·沙泽尔、尼基·帕尔马尔、雅各布·乌兹科雷特、利昂·琼斯、艾丹·N·戈麦斯、卢卡斯·凯泽和伊利亚·波洛苏欣。注意力就是一切。见《神经信息处理系统进展》, 第 30 卷, 2017 年。
- [39] 王国庆、王中道、唐品、郑继来、任祥轩、冯白兰和马超。Occgen: 用于自动驾驶的生成式多模态 3D 占用预测。arXiv 预印本 arXiv:2404.15014, 2024。
- [40] 王鹏钦、朱美鑫、陆洪亮、钟辉、陈贤达、沈少杰、王学松和王银海。BevGPT: 用于自动驾驶预测、决策和规划的生成式预训练大模型。arXiv 预印本 arXiv:2310.10357, 2023。
- [41] 王天奇、金锡民、季文轩、谢恩泽、葛崇剑、陈俊松、李振国、罗平。Deepaccident: 面向车路协同自动驾驶的运动与事故预测基准。发表于《AAAI》, 第 38 卷, 第 5599-5606 页, 2024 年。
- [42] 王晓峰、朱正、黄冠、陈新泽和吕继文。Drivedreamer: 面向自动驾驶的真实世界驱动世界模型。arXiv 预印本 arXiv:2309.09777, 2023。
- [43] 王晓峰、朱正、徐文博、张运鹏、魏毅、迟旭、叶云、杜大龙、吕继文和王兴刚。Openoccupancy: 一个用于周围语义占据感知的大规模基准。发表于《ICCV》, 第 17850-17859 页, 2023 年。
- [44] 易伟、赵林清、郑文昭、朱正、周杰、陆继文。Surroundocc: 自动驾驶中的多相机三维占用预测。《国际计算机视觉大会论文集》, 第 21729-21740 页, 2023 年。
- [45] 威尔逊·闫、张云志、皮特·阿比尔和阿拉文·斯里尼瓦斯。Videogpt: 使用 vq-vae 和 transformers 生成视频, 2021 年。
- [46] 杨晨宇、陈运涛、田浩、陶辰鑫、朱稀州、张兆翔、黄高、李宏阳、乔宇、卢乐炜等。Bevformer v2: 通过透视监督使现代图像骨干网络适应鸟瞰图识别。《CVPR》, 第 17830-17839 页, 2023 年。
- [47] 雷阳、于凯程、唐涛、李俊、袁坤、王立、张新宇和陈鹏。Bevheight: 一种基于视觉的路边三维目标检测鲁棒框架。发表于《CVPR》, 第 21611-21620 页, 2023 年。

- [48] 于海宝、唐英娟、谢恩泽、毛吉磊、罗平、聂再清。基于流的特征融合在车路协同 3D 目标检测中的应用。《神经信息处理系统讲展》。第 36 卷。2024 年。
- [49] 张吉和丁一然。Occfusion: 无需深度估计的多传感器融合用于 3D 占用预测。arXiv 预印本 arXiv:2403.05329。2024。
- [50] 张云鹏、朱正和杜大龙。《Occformer: 用于基于视觉的 3D 语义占用预测的双路径 Transformer》。收录于《ICCV》第 9433-9443 页。2023 年。
- [51] 张云鹏、朱正、郑文昭、黄俊杰、黄冠、周洁和陆继文。Beverse: 面向视觉中心自动驾驶的鸟瞰图统一感知与预测。2022。
- [52] 赵渊、张璐、邓家军、张彦勇。BEV-Radar: 用于三维目标检测的双向雷达 - 相机融合。《中国科学技术大学学报》。54 (1): 0101-1。2024。
- [53] 郑文昭、陈威良、黄元辉、张柏瑞、段月琪和吕继文。Occworld: 为自动驾驶学习 3D 占用世界模型。arXiv 预印本 arXiv:2311.16038。2023。
- [54] 郑文昭、宋瑞琪、郭显达和陈龙。Genad: 生成式端到端自动驾驶。arXiv 预印本 arXiv:2402.11502, 2024。
- [55] 周子祥、张阳和哈桑·福鲁什。Panoptic-polarnet: 无提议的激光雷达点云全景分割。见《CVPR》, 第 13194-13203 页。2021 年。
- [56] 左思成、郑文昭、黄元辉、周杰和吕继文。Pointocc: 基于点的三维语义占用预测的圆柱三视图。arXiv 预印本 arXiv:2308.16896, 2023。

A 附录

A.1 更多可视化结果

为了提供更长时间序列的结果，我们在图 10 中展示了在不同自车轨迹控制下生成的场景，即直行、右转、静止和加速。此外，我们还在图 11 中展示了不同场景下的等效控制方法。



图 10: 在不同轨迹控制下生成长时间序列 4D 占用率的能力。从上到下，我们展示了在四种自车轨迹下生成的长期连续场景：直行、右转、静止和加速。




图 11: 在固定自车轨迹下生成不同场景的泛化能力。从上到下, 我们展示了在四种车辆轨迹下生成不同场景的能力: 直行、右转、静止和加速。